

Estudio de la tendencia de las capturas reconstruidas del área FAO 34 desde 1950 a 2018

Víctor Sanz Fernández

10/01/2020

Índice

1. Presentación del trabajo	
2. Área de estudio	
2.1. FAO 34 o Atlántico Centro Oriental	
3. Lectura de datos y generación de la serie temporal	
4. Representación de la serie temporal	
5. Aplicación del método de regresión	
5.1. Tendencia lineal temporal	
5.2. Tendencia cuadrática temporal	
6. Representación visual de los modelos presentados	
6.1. Tendencia lineal temporal	
6.2. Tendencia cuadrática temporal	
7. Conclusiones	
8. Referencias	

1. Presentación del trabajo

El objetivo de este trabajo es realizar un informe y análisis reproducible con R y Rmarkdown. Para ello, se aplicarán los conocimientos adquiridos durante la realización del curso: ‘Informes y análisis reproducibles con R y Rmarkdown’ celebrado durante los días 10, 11, 17 y 18 de diciembre de 2020 organizado por el Centro de Estudios Andaluces (Junta de Andalucía) e impartido por el Doctor David García Callejas.

Para la realización del presente ejercicio se utiliza la base de datos de capturas marinas reconstruidas de Sea Around Us (Zeller et al. 2016), disponible en **Sea Around US**¹. Esta base de datos está compuesta por

¹Las palabras en negrita significan que están vinculadas a un enlace web.

registros de capturas globales marinas de 1146 especies piscícolas sometidas a explotación con una cobertura temporal de 1950 a 2018.

Los registros de capturas son presentados para un determinado taxón/especie en un año específico, procedente de 6 áreas geolocalizadas: zona exclusiva económica, grandes ecosistemas marinos, ecorregiones marinas, organizaciones regionales de gestión pesquera, áreas globales y FAOs.² Cada una de estas áreas está agrupada por:

1-Sector pesquero (industrial, artesanal de subsistencia y recreativo).

2-Países.

3-Tipos de artes de pesca.

Los datos reconstruidos resultan de la combinación entre los datos oficiales comunicados y estimaciones de datos no comunicados (principalmente descartes) o no declarados. Las estimaciones de los datos no comunicados se realizan para los cuatro sectores de pesca. Los datos oficiales se extraen de las bases de datos FishStat de la **FAO**.

Así, a partir de esta base de datos filtrada por el área FAO 34 se pretende construir y analizar la evolución temporal de las capturas reconstruidas de 1950 a 2018, además de estudiar la tendencia lineal mediante la aplicación de métodos de regresión. La variable de estudio es “*tonnes*” que representa las capturas reconstruidas totales en toneladas, obtenidas como la suma de los desembarcos más los descartes procedentes de los diferentes estados del reporte, sectores pesqueros, artes de pesca y uso final. Los datos concretos del área FAO 34 pueden ser descargados en **FAO 34**.

2. Área de estudio

2.1. FAO 34 o Atlántico Centro Oriental

El área FAO 34 se localiza en el atlántico centro oriental (36° N, 30-40° W, 6° S) frente a la costa occidental de África, abarcando desde el Estrecho de Gibraltar hasta la desembocadura del río Zaire (frontera entre República Democrática del Congo y Congo). Cuenta con una extensión de 14,074,956 km², se subdivide en 4 subáreas y la FAO la cataloga como área de afloramiento.

```
knitr::include_graphics("Zonas FAO.jpg")
```

3. Lectura de datos y generación de la serie temporal

En este apartado se procede a la carga de los datos, su lectura y preparación del conjunto de datos para la aplicación del método de regresión.

```
#Lectura de datos
FAO34 <-read.csv("SAU FAO 34 v48-0.csv", header = T)

#Dimensión del conjunto de datos: 638156 observaciones y 14 variables
dim(FAO34)
```

```
## [1] 638156      14
```

²FAO = Organización de las Naciones Unidas para la Agricultura y la Alimentación.

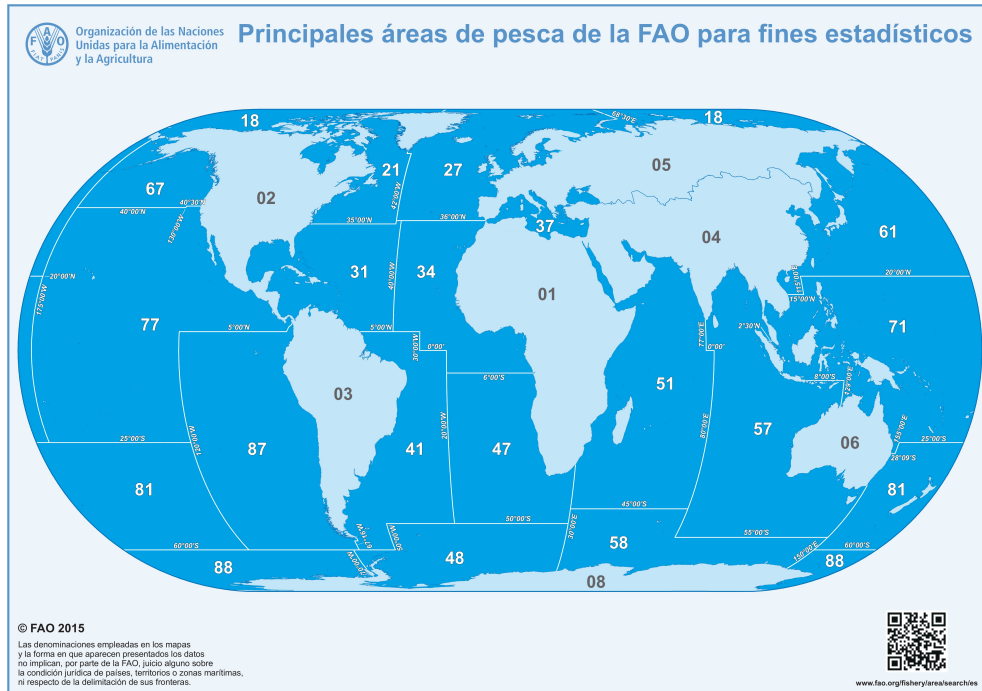


Figura 1: Localización del área FAO 34.

```
#Resumen estadístico de nuestra variable de estudio: tonnes (toneladas)
summary(FA034$tonnes)
```

```
##      Min.   1st Qu.   Median     Mean   3rd Qu.     Max.
##      0.0      0.7     16.8    1181.1    188.2 1131470.2
```

```
#Definimos a la variable year como factor
FA034$fYear <- factor(FA034$year)

#Creamos un nuevo data frame con la serie anual global calculada
FA034_Anuual<-as.data.frame(aggregate(tonnes ~ fYear,
                                     data = FA034, FUN = sum))

#Definimos la serie anterior como una serie temporal
FA0global34<-ts(FA034_Anuual$tonnes,start=1950,frequency=1)

#Obtenemos la variable temporal y la incorporamos a nuestro
#conjunto de datos FA034_Anuual
FA034_Anuual$time<- time(FA0global34)
```

4. Representación de la serie temporal

Una vez generada nuestra serie temporal procedemos a representarla. Para ello, empleamos el siguiente código:

```

ggplot()+
  geom_line(data = FA034_Anual,
            aes(y = (tonnes)/1000, x = time),
            linetype="solid",
            size = 0.5)+
  theme_classic()+
  labs(x="Años",y="Capturas (toneladas x 1000)")+
  ggtitle("Capturas reconstruidas para el área FAO 34 (1950-2018)")+
  theme (plot.title = element_text(family="serif",
                                   size=rel(1.4),
                                   vjust=0.5,
                                   hjust=0.5,
                                   face="bold",
                                   color="black",
                                   lineheight=1.5))+
  scale_y_continuous(breaks=seq(0, 16000, 2000),limits =c(0,16000))+
  scale_x_continuous(breaks=c(1950,1960,1970,1980,1990,2000,2010,2020),
                    labels=c("1950","1960","1970","1980","1990",
                              "2000","2010","2020"))+
  theme(axis.text.x = element_text( vjust=-0.5, colour="black",
                                    size=rel(1.4), family="serif"))+
  theme(axis.text.y = element_text( vjust=0.4, colour="black",
                                    size=rel(1.4), family="serif"))+
  theme(axis.line.x=element_line(color="black", size=0.5))+
  theme(axis.line.y=element_line(color="black", size=0.5))+
  theme(axis.title.x = element_text( vjust=-0.5, colour="black",
                                    size=rel(1.4),family = "serif"))+
  theme(axis.title.y = element_text( vjust=1.5, colour="black",
                                    size=rel(1.4),family="serif"))+
  NULL

```




Figura 2: Evolución histórica de las capturas reconstruidas del área FAO 34.

En la figura 2, se observa como las capturas aumentan desde 1950 hasta la década de los años 80, donde a partir de ahí se estabilizan oscilando entre [12000-16000] x 1000 toneladas hasta el año 2018. Se aprecia claramente cómo las capturas aumentan desde su inicio en 1950 con 1756.046 x 1000 toneladas hasta su final con 13581.17 x 1000 toneladas, lo que supone un incremento de 673.39 % del año 2018 respecto del año 1950.

```
#Cálculo del porcentaje de variación de las capturas
#del año 2018 respecto del año 1950
```

```
#Seleccionamos el dato de toneladas del año 2018
```

```
Capturas_2018 = subset (FAO34_Anual, time=="2018")
Capturas_2018 = Capturas_2018[, -c(1,3)]
```

```
#Seleccionamos el dato de toneladas del año 1950
```

```
Capturas_1950 = subset (FAO34_Anual, time=="1950")
Capturas_1950 = Capturas_1950[, -c(1,3)]
```

```
#Calculamos el porcentaje como:
```

```
((Capturas_2018-Capturas_1950)/Capturas_1950)*100
```

```
## [1] 673.3949
```

5. Aplicación del método de regresión

Se utiliza un método estadístico clásico de análisis de regresión para estimar los parámetros de los modelos comunes de tendencia. Para ello, emplearemos tendencias lineales y cuadráticas temporales.

5.1. Tendencia lineal temporal

En este apartado se calcula una tendencia determinista lineal (orden 1) temporal, estimando la pendiente y el intercepto mediante la regresión de mínimos cuadrados. La tendencia temporal lineal es expresada como:

$$\mu_0 = \beta_0 + \beta_1 * t \quad (1)$$

donde μ_0 es la tendencia temporal determinista, β_0 es el intercepto, β_1 es la pendiente y t es el tiempo (años en nuestro caso). De tal manera que la aplicación de la ecuación (1) a nuestros datos quedaría:

$$toneladas_0 = \beta_0 + \beta_1 * años \quad (2)$$

Donde “ $toneladas_0$ ” hace referencia a la tendencia de las toneladas.

5.1.1. Aplicación del modelo

A continuación, aplicamos la ecuación (2) a nuestros datos:

```
#Aplicación del modelo
tendencia_lineal <- lm(tonnes ~ I(time), data =FAO34_Anual)
```

```
#Tabla resumen estadístico del modelo
stargazer::stargazer(tendencia_lineal,label="tabla1",
  header=FALSE,
  title = "Parámetros, errores estándares,
  valores-z y p-valores estimados por la ecuación (2).")
```

Cuadro 1: Parámetros, errores estándares, valores-z y p-valores estimados por la ecuación (2).

<i>Dependent variable:</i>	
tonnes	
I(time)	205,365.500*** (16,002.770)
Constant	-396,521,639.000*** (31,751,104.000)
Observations	69
R ²	0.711
Adjusted R ²	0.707
Residual Std. Error	2,647,480.000 (df = 67)
F Statistic	164.689*** (df = 1; 67)
<i>Note:</i>	*p<0.1; **p<0.05; ***p<0.01

5.1.2. Interpretación del modelo

A partir del cuadro 1, observamos que el sobre 71 % de la variación en la serie temporal de las capturas es explicada por la tendencia temporal lineal, siendo todos los parámetros de la tendencia claramente significativos. El signo de la tendencia es positivo tal y como indica la pendiente. Por tanto, siguiendo la ecuación (2) y los resultados del cuadro 1 el modelo quedaría como:

$$toneladas_0 = -396521,639 * (1000) + 205,365 * (1000) * \text{años} \quad (3)$$

5.1.3. Análisis de los residuos

Una vez interpretado nuestro modelo, pasamos a validarlo mediante el análisis de sus residuos ordinarios calculados como:

$$residuo_i = y_i - \hat{y}_i \quad (4)$$

donde $residuo_i$ es el residuo ordinario para un año i , y_i es el valor observado de la captura en el año i y \hat{y}_i es el valor predicho de la captura por la ecuación (3) para un año i . Si el modelo generado es correcto, los residuos generados deben ser un ruido blanco, es decir, que no tengan ninguna estructura de dependencia significativa, además deber ser normales, homogéneos y carecer de valores influyentes en los valores ajustados del modelo. Todo este análisis se realiza mediante gráficos.

```
#Extracción de los valores ajustados por el modelo de la ecuación 3
F1 <- fitted(tendencia_lineal)
#Extracción de los residuos
E1 <- resid(tendencia_lineal)
```

```
par(mar = c(4, 4, 2, 2))
plot(x = F1, y = E1,
     type="p",
     xlab = "Valores ajustados de la tendencia",
     ylab = "Residuos",
     main = "¿Homogeneidad?")
abline(h = 0, v = 0, lty = 2)
plot(x = as.vector(FA034_Anual$time), y = E1,
     type="l",
     xlab = "Años",
     ylab = "Residuos",
     main = "¿Homogeneidad?")
abline(h = 0, v = 0, lty = 2)
```




Figura 3: Estudio de la homogeneidad.

Para estudiar la homogeneidad se representan los residuos vs los valores ajustados (**izquierda**) y los residuos vs el tiempo (**derecha**) (Fig. 3). Una serie es homocedástica cuando su variabilidad es constante a lo largo del tiempo. La variabilidad se refiere al “grosor” de la serie, es decir, si los residuos fuesen homogéneos deberíamos observar la misma extensión por cualquier lado. En la figura 3 podemos observar como la variabilidad o el grosor de la serie se mantiene constante a lo largo del tiempo, lo que estaría indicando que los residuos son homocedásticos.

Para estudiar la normalidad se realiza el histograma de los residuos (**izquierda**) y su correspondiente gráfico Q-Q (**derecha**) (Fig. 4). En la figura 4 podemos observar que existe una dispersión de los residuos por la colas con un amplio rango de frecuencia, indicando que los residuos no son normales. Este aspecto es discutible en los métodos de regresión, aunque es importante, no es aspecto crucial en la validación del modelo.

```
par(mar = c(4, 4, 2, 2))
hist(E1, main = "Normalidad", breaks=10)
qqnorm(E1)
qqline(E1)
```

Para el estudio de la independencia de los residuos, se representan los residuos vs el tiempo (**izquierda**) y su función de autocorrelación (ACF) (**derecha**) (Fig. 5), que mide la correlación existente entre los datos




Figura 4: Estudio de la normalidad.

de la serie temporal separados por k desfases o *lags*, indicando, si los valores pasados influyen sobre los presentes, de tal modo que, si las observaciones fuesen independientes no habría correlación significativa. En la figura 5, observamos como existe un patrón no lineal de los residuos, además de bloques importantes de correlaciones significativas (palos fuera de las bandas de confianza). Si los residuos fuesen independientes no se tendrían que observar patrones ni correlaciones significativas.

```
par(mar = c(4, 4, 3, 3))
plot(x = as.vector(FA034_Anual$time), y = E1,
     type="l",
     xlab = "Años",
     ylab = "Residuos",
     main = "¿Independencia?")
abline(h = 0, v = 0, lty = 2)
acf(E1, lag.max=42, main = "¿Independencia?")
```

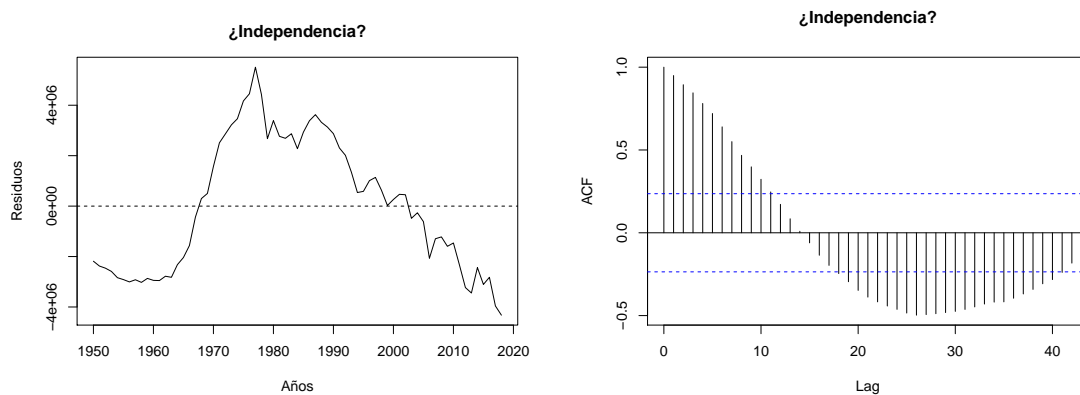


Figura 5: Estudio de la independencia.

Finalmente, las observaciones influyentes se estudian mediante la aplicación de la distancia de Cook. En la figura 6, no aparecen observaciones influyentes en los valores ajustados por el modelo.

```
plot(cooks.distance(tendencia_lineal), type = "h", ylim = c(0, 1))
abline(h = 1, col = 2, lwd = 3)
```





Figura 6: Estudio de los valores influyentes.

5.1.4. Conclusiones de la tendencia lineal temporal

Tras la aplicación del método de regresión, se ha visto como el 71 % de la variación en la serie temporal de las capturas es explicada por una tendencia temporal lineal negativa significativa, siendo además todos los parámetros del modelo significativos. El análisis de los residuos indicó que estos no seguían un estructura de ruido blanco y no eran normales, pero sí homocedásticos y el modelo no tuvo valores ajustados con observaciones influyentes. El hecho de encontrar patrones en los residuos, causantes de la no independencia, podría estar indicando la necesidad de incluir al modelo un nuevo término que sea capaz de reducir estos patrones. Por este motivo se realiza de nuevo todo el análisis anterior incorporando al modelo de la ecuación (1) un término cuadrático, ajustando una tendencia cuadrática temporal.

5.2. Tendencia cuadrática temporal

En este apartado se calcula una tendencia determinista cuadrática (orden 2) temporal a partir de la siguiente ecuación:

$$\mu_0 = \beta_0 + \beta_1 * t + \beta_2 * t^2 \quad (5)$$

donde μ_0 es la tendencia temporal determinista, β_0 es el intercepto, β_1 es la pendiente de orden 1, β_2 es la pendiente de orden 2 y t es el tiempo (años en nuestro caso). De tal manera que la aplicación de la ecuación (5) a nuestros datos quedaría:

$$toneladas_0 = \beta_0 + \beta_1 * \text{años} + \beta_2 * \text{años}^2 \quad (6)$$

Donde “ $toneladas_0$ ” hace referencia a la tendencia de las toneladas.

5.2.1. Aplicación del modelo

Aplicamos la ecuación (6) a nuestros datos:

```
#Aplicación del modelo
tendencia_cuadratica <- lm(tonnes ~ I(time) + I(time^2), data =FA034_Anual)
```

```
#Tabla resumen estadístico del modelo
stargazer::stargazer(tendencia_cuadratica,label="tabla2",
  header=FALSE,
  title = "Parámetros, errores estándares,
  valores-z y p-valores estimados por la ecuación (6).")
```

Cuadro 2: Parámetros, errores estándares, valores-z y p-valores estimados por la ecuación (6).

	<i>Dependent variable:</i>
	tonnes
I(time)	25,885,258.000*** (1,707,400.000)
I(time^2)	-6,471.747*** (430.288)
Constant	-25,868,407,631.000*** (1,693,621,460.000)
Observations	69
R ²	0.935
Adjusted R ²	0.933
Residual Std. Error	1,267,703.000 (df = 66)
F Statistic	472.249*** (df = 2; 66)
<i>Note:</i>	*p<0.1; **p<0.05; ***p<0.01

5.2.2. Interpretación del modelo

A partir del cuadro 2, apreciamos que el porcentaje de variación explicado por la tendencia temporal cuadrática se ha incrementado un 23 %, pasando a ser del 93 %, en comparación con el modelo de tendencia temporal lineal. Al igual que ocurrió con el modelo anterior, todos los parámetros de este nuevo modelo son significativos. EL signo de la pendiente de orden 1 es positivo mientras que el de orden 2 es negativo. Siguiendo la ecuación (6) y los resultados del cuadro 2 el modelo quedaría como:

$$\text{toneladas}_0 = -25868408 * (1000) + 25885,26 * (1000) * \text{años} - 6,471747 * (1000) * \text{años}^2 \quad (7)$$

5.2.3. Análisis de los residuos

Procedemos a realizar el mismo análisis de los residuos que hicimos con el modelo anterior.

```
#Extracción de los valores ajustados por el modelo de la ecuación 7
F2 <- fitted(tendencia_cuadratica)
#Extracción de los residuos
E2 <- resid(tendencia_cuadratica)
```

En la figura 7 se representan los residuos vs los valores ajustados (**izquierda**) y los residuos vs el tiempo (**derecha**). Observamos que existe una dispersión o aumento de grosor de la serie en su parte final, indicando que la homogeneidad no se cumpliría a lo largo de toda la serie.

```

par(mar = c(4, 4, 2, 2))
plot(x = F2, y = E2,
     type="p",
     xlab = "Valores ajustados de la tendencia",
     ylab = "Residuos",
     main = "¿Homogeneidad?")
abline(h = 0, v = 0, lty = 2)
plot(x = as.vector(FA034_Anual$time), y = E2,
     type="l",
     xlab = "Años",
     ylab = "Residuos",
     main = "¿Homogeneidad?")
abline(h = 0, v = 0, lty = 2)

```




Figura 7: Estudio de la homogeneidad.

Se realiza el histograma de los residuos (**izquierda**) y su correspondiente gráfico Q-Q (**derecha**) (Fig. 8). Apreciamos cómo los residuos son normales.

```

par(mar = c(4, 4, 2, 2))
hist(E2, main = "Normalidad", breaks=10)
qqnorm(E2)
qqline(E2)

```




Figura 8: Estudio de la normalidad.

Para la independencia de los residuos, se representan los residuos vs el tiempo (**izquierda**) y su función de autocorrelación (ACF) (**derecha**) (Fig. 9). Observamos cómo siguen existiendo patrones en los residuos, además de bloques importantes de correlaciones significativas (palos fuera de las bandas de confianza). Aunque en comparación con el modelo anterior, podemos ver cómo la incorporación del término cuadrático ha reducido la intensidad de estos patrones, llegando a aparecer bloques temporales en torno al cero sin correlaciones significativas, indicando que aproximadamente a partir de desfases de 20 años, no existe influencia significativa de los valores pasados sobre los presentes.

```
par(mar = c(4, 4, 3, 3))
plot(x = as.vector(FA034_Anuales$time), y = E2,
     type="l",
     xlab = "Años",
     ylab = "Residuos",
     main = "¿Independencia?")
abline(h = 0, v = 0, lty = 2)
acf(E2, lag.max=42, main = "¿Independencia?")
```




Figura 9: Estudio de la independencia.

Por último, en la figura 10 no aparecen observaciones influyentes.

```
plot(cooks.distance(tendencia_cuadratica), type = "h", ylim = c(0, 1))
abline(h = 1, col = 2, lwd = 3)
```




Figura 10: Estudio de los valores influyentes.

5.2.4. Conclusiones de la tendencia cuadrática temporal

Tras la realización de este nuevo modelo, hemos visto como el porcentaje de la variación explicada por la tendencia de las capturas ha aumentado hasta un 93 %. La tendencia cuadrática fue significativa, presentando distintos signos en función del orden temporal, siendo positiva para un orden 1 y negativa para un orden 2. Todos los parámetros del modelo fueron significativos. La incorporación del término cuadrático produjo una amortiguación de los patrones de los residuos, ocasionando que estos presentasen bloques similares a un ruido y además hizo que los residuos fuesen normales, pero aumentó su dispersión. Igual que en el caso de la tendencia lineal temporal, el modelo cuadrático no tuvo valores ajustados con observaciones influyentes.

6. Representación visual de los modelos presentados

El objetivo de este apartado es visualizar el comportamiento de los modelos ajustados para ello seguimos los siguientes pasos:

- 1- Creamos una serie de valores de años, digamos por ejemplo 25 años.
- 2- Predecimos los valores de la tendencia para esos 25 valores.
- 3- Calculamos los intervalos de confianza al 95 %.
- 4- Dibujamos los valores de años predichos de tendencia frente a la serie original.

6.1. Tendencia lineal temporal

Para realizar los pasos anteriores utilizaremos la ecuación (3).

```
#Paso 1
MyTL <- data.frame(time = seq(from = 1950,
                              to = 2018,
                              length = 25))

#Paso 2
TL <- predict(tendencia_lineal, newdata = MyTL, se = TRUE, type = "response")

#Paso 3
MyTL$Pred <- TL$fit                                #Valor predicho
MyTL$seup <- TL$fit + 1.96 * TL$se.fit             #Valor superior del intervalo de confianza al 95%
MyTL$selo <- TL$fit - 1.96 * TL$se.fit             #Valor inferior del intervalo de confianza al 95%
```

6.2. Tendencia cuadrática temporal

Para realizar los pasos anteriores utilizaremos la ecuación (7).

```
#Paso 1
MyTC <- data.frame(time = seq(from = 1950,
                              to = 2018,
                              length = 25))

#Paso 2
TC <- predict(tendencia_cuadratica, newdata = MyTC, se = TRUE, type = "response")

#Paso 3
MyTC$Pred <- TC$fit                                #Valor predicho
```

```
MyTC$seup <- TC$fit + 1.96 * TC$se.fit #Valor superior del intervalo de confianza al 95%
MyTC$selo <- TC$fit - 1.96 * TC$se.fit #Valor inferior del intervalo de confianza al 95%
```

```
#Representación visual de los modelos
par(mar = c(4, 4, 3, 3))
#Modelo lineal
ggplot()+
geom_line(data = FA034_Anual,
          aes(y = (tonnes)/1000, x = time),
          linetype="solid",
          size = 0.5)+
theme_classic()+
labs(x="Años",y="Capturas (toneladas x 1000)")+
scale_y_continuous(breaks=seq(0, 20000, 5000),limits =c(0,20000))+
scale_x_continuous(breaks=c(1950,1960,1970,1980,1990,2000,2010,2020),
                  labels=c("1950","1960","1970","1980","1990","2000","2010","2020"))+
theme(text = element_text(size=15))+
theme(legend.position="")+
geom_line(data = MyTL,
          aes(x = time, y = (Pred)/1000),
          colour = "red")+
geom_ribbon(data = MyTL,
           aes(x = time,
              ymax = (seup)/1000,
              ymin = (selo)/1000,
              alpha = 0.5))+
theme(axis.text.x = element_text( vjust=-0.5, colour="black",
                                  size=rel(1.2), family="serif"))+
theme(axis.text.y = element_text( vjust=0.4, colour="black",
                                  size=rel(1.2), family="serif"))+
theme(axis.line.x=element_line(color="black", size=0.5))+
theme(axis.line.y=element_line(color="black", size=0.5))+
theme(axis.title.x = element_text( vjust=-0.5, colour="black",
                                   size=rel(1.2),family = "serif"))+
theme(axis.title.y = element_text( vjust=1.5, colour="black",
                                   size=rel(1.2),family="serif"))+
NULL

#Modelo cuadrático
ggplot()+
geom_line(data = FA034_Anual,
          aes(y = (tonnes)/1000, x = time),
          linetype="solid",
          size = 0.5)+
theme_classic()+
labs(x="Años",y="Capturas (toneladas x 1000)")+
scale_y_continuous(breaks=seq(0, 20000, 5000),limits =c(0,20000))+
scale_x_continuous(breaks=c(1950,1960,1970,1980,1990,2000,2010,2020),
                  labels=c("1950","1960","1970","1980","1990","2000","2010","2020"))+
theme(text = element_text(size=15))+
theme(legend.position="")+
geom_line(data = MyTC,
          aes(x = time, y = (Pred)/1000),
```

```

    colour = "red")+
geom_ribbon(data = MyTC,
    aes(x = time,
        ymax = (seup)/1000,
        ymin = (selo)/1000,
        alpha = 0.5))+
theme(axis.text.x = element_text( vjust=-0.5, colour="black",
    size=rel(1.2), family="serif"))+
theme(axis.text.y = element_text( vjust=0.4, colour="black",
    size=rel(1.2), family="serif"))+
theme(axis.line.x=element_line(color="black", size=0.5))+
theme(axis.line.y=element_line(color="black", size=0.5))+
theme(axis.title.x = element_text( vjust=-0.5, colour="black",
    size=rel(1.2),family = "serif"))+
theme(axis.title.y = element_text( vjust=1.5, colour="black",
    size=rel(1.2),family="serif"))+
NULL

```




Figura 11: Ajuste del modelo lineal a partir de la ecuación 3 (izquierda) y del modelo cuadrático a partir de la ecuación 7 (derecha).

7. Conclusiones

En la figura 11 podemos observar el ajustes de los modelos, en principio apreciamos como el modelo cuadrático se ajusta mejor a la forma de la serie de las capturas. Por tanto según nuestros análisis, el modelo seleccionado para el estudio de la tendencia de las capturas reconstruidas desde 1950 a 2018 para el área FAO 34 podría ser el modelo cuadrático, ya que presentó mayor coeficiente de determinación y mejores resultados estadísticos del análisis de los residuos y visuales, indicando que la tendencia de las capturas se ajusta mejor a una tendencia de tipo no lineal. Los residuos del modelo seleccionado presentan todavía patrones y una ligera dispersión, ocasionando que su interpretación sea tomada con cautela, pero todos sus términos son muy significativos y razonablemente robustos. Ante esta situación, para eliminar estos patrones, otras técnicas estadísticas podrían ser planteadas como: modelos generalizados (GLM), modelos generalizados mixtos (GLMM), modelos aditivos generalizados (GAM), modelos aditivos generalizados mixtos (GAMM), modelos generalizados de mínimos cuadrados (GLS) y modelos autorregresivos integrados de medias móviles (ARIMA), entre otras. De todas maneras, los modelos presentados en este trabajo, podría ser utilizados como una primera aproximación para detectar el patrón general de la serie y ayudar a comprender su comportamiento, siendo conscientes de la limitación de los mismos y el propósito de su utilización. En este estudio, el modelo seleccionado se utilizó para comprender y visualizar el patrón general y la tendencia de la serie.

8. Referencias

Zeller, Dirk, ML Deng Palomares, Arash Tavakolie, Melanie Ang, Dyhia Belhabib, William WL Cheung, Vicky WY Lam, etal. 2016. «Still catching attention: Sea Around Us reconstructed global catch data, their spatial expression and public accessibility». *Marine Policy* 70: 145-52.